

비만 위험군 선별 프로젝트 (day06/project_v1)

문진(설문) 응답만으로, 비만이 될 위험이 큰 사람을 검사 전에 미리 가려내는 프로젝트입니다.

1. 왜 이 문제인가

- **누가 쓰나:** 보건소나 1차 진료에서 일하는 영양 상담사
- **무엇을 결정하나:** 문진 응답을 바탕으로, 이 사람을 비만 위험군으로 보고 영양 상담을 먼저 권할지 말지
- **언제 결정하나:** 체성분 검사 같은 정밀 검사를 받기 전, 문진 응답을 받은 직후

이 판단이 늦으면 비만 단계를 늦게 알게 되어 식단·운동 개입 시작이 늦어지고, 과체중을 지나 고도비만까지 진행될 수 있습니다. 원래는 정밀 검사를 받아야 알 수 있는 걸, 검사 전 문진 단계에서 미리 짐작할 수 있게 해주는 게 이 프로젝트의 목적입니다.

2. 데이터

- **출처:** UCI Machine Learning Repository - "Estimation of obesity levels based on eating habits and physical condition" (Kaggle에도 같은 데이터가 올라와 있습니다)
- **원본 규모:** 2111행 x 17열
- **정제:** 완전히 같은 값이 두 번 이상 들어간 중복행 24건을 제거해서 **2087행 x 17열**로 정리했습니다. 빈칸이 많은 열이나 값이 하나로 고정된 열은 없어서 열 개수는 그대로입니다.
- **결과 열(맞혀야 하는 것):** `NObeyesdad` (비만 단계, 7종: 저체중~고도비만 3단계). 이 프로젝트에서는 `Obesity_Type_I/II/III` (비만)이면 1, 나머지 4종(저체중·정상·과체중 2단계)이면 0으로 둘로 나눠서(이진화) 썼습니다. 전체 2087건 중 비만은 972건(46.6%)입니다.
- **입력으로 쓴 열 (6개):** 원래 8개의 숫자 열 중 아래 6개만 씁니다.
 - `Age` (나이)
 - `FCVC` (채소를 얼마나 자주 먹는지)
 - `NCP` (하루에 주식을 몇 끼 먹는지)
 - `CH2O` (하루 물 섭취량)
 - `FAF` (운동을 얼마나 자주 하는지)
 - `TUE` (전자기기 사용 시간)
- **뺀 열 (2개, 이유 있음):** `Height` (키), `Weight` (몸무게)는 뺐습니다. 이 둘로 BMI(몸무게÷키²)를 계산해보면 `NObeyesdad` 클래스 범위와 거의 겹치지 않을 만큼 딱 맞아떨어집니다 — 즉 결과 열을 다른 모양(키·몸무게)으로 숨겨놓은 것에 가깝습니다. 그대로 넣으면 모델이 진짜 생활습관을 배우는 게 아니라 BMI 계산기처럼 동작하게 되고, "정밀 검사 전에 미리 가려낸다"는 목적과도 어긋나서 뺐습니다.

3. 무엇을 했나

1. **정제**: 중복행 24건 제거
2. **변수 선택**: 위에서 설명한 이유로 `Height`, `Weight` 제외, 숫자 열 6개만 입력으로 사용
3. **빈칸 채우기**: 입력 열에 빈칸이 있으면 그 열의 중앙값으로 채우도록 준비했으나, 실제로는 빈칸이 없었습니다
4. **학습·시험 나누기**: 8:2로 나누고, 비만 비율(46.6%)이 양쪽에 똑같이 가도록 맞췄습니다 (학습 1669건, 시험 418건)
5. **모델**: 값을 같은 단위로 맞추는 표준화를 한 뒤, 로지스틱 회귀(분류 모델)를 학습시켰습니다. 기본 버전과, 드문 쪽(비만)에 더 무게를 두는 `class_weight="balanced"` 버전 두 가지를 만들었습니다
6. **검증**: 혼동행렬(실제값 × 예측값을 4칸으로 나눠 세는 표)로 결과를 확인했습니다

4. 결과 수치

기준 모델(아무것도 배우지 않고 무조건 "비만 아님"이라고만 답하는 비교용 모델)의 정확도는 53.35%였습니다. 실제로 학습시킨 모델(v1)의 정확도는 65.55%로, 12.20%p 올랐습니다.

시험용 418건을 혼동행렬로 나누면 이렇습니다.

	예측: 비만 아님	예측: 비만	실제 합계
실제: 비만 아님	163건 (맞음)	60건 (헛지목)	223건
실제: 비만	84건 (놓침)	111건 (제대로 잡음)	195건

- **정밀도**(모델이 "비만"이라고 지목한 것 중 진짜였던 비율): $111/171 = 0.649$
- **재현율**(실제 비만인 사람 중 모델이 잡아낸 비율): $111/195 = 0.569$


즉 모델이 "비만"이라고 지목한 171명 중 60명(35%)은 틀린 지목이고, 실제 비만 195명 중 84명(43%)은 놓쳤습니다. 정확도만 보면 나아 보이지만, 재현율이 낮아서 "위험군을 미리 가려낸다"는 원래 목적에는 아직 부족합니다.


`class_weight="balanced"` 버전과 비교


	지목 건수	그중 진짜	재현율	정밀도
기본 모델	171건	111건	0.569	0.649
가중치 모델	197건	122건	0.626	0.619

가중치를 준 모델은 더 많이 지목해서(171→197건) 놓치는 사람은 줄었지만(84명→73명), 대신 헛지목은 늘었습니다(60건→75건). 즉 "놓치는 걸 줄이는 대신 헛지목을 좀 더 감수하는" 방향입니다.

5. 결과 그림







6. 앱 화면

같은 데이터·같은 분석을 day08의 Streamlit 분석 앱(`day08/lab25_analysis_app`)으로 직접 눌러 본 화면입니다.

비만 위험군 선별 프로젝트

문진(설문) 응답만으로, 비만이 될 위험이 큰 사람을 검사 전에 미리 가려내는 프로젝트

데이터 훑기 전처리 학습 결과 리포트

CSV 파일을 올려주세요

 Obesity..._clean.csv 268.3KB +

행 2087개, 열 17개

	Age	Gender	Height	Weight	CALC	FAVC	FCVC	NCP	SCC	SMOKE	CH2O	famil
0	21	Female	1.62	64	no	no	2	3	no	no	2	yes
1	21	Female	1.52	56	Sometimes	no	3	3	yes	yes	3	yes
2	23	Male	1.8	77	Frequently	no	2	3	no	no	2	yes
3	27	Male	1.8	87	Frequently	no	3	3	no	no	2	no
4	22	Male	1.78	89.8	Sometimes	no	2	1	no	no	2	no

빈칸 : 전체 0개

빈칸 없음

맞는 열인지 확인하세요

결과 열을 고르세요

NObeyesdad

NObeyesdad	건수	비율(%)
Obesity_Type_I	351	16.8
Obesity_Type_III	324	15.5
Obesity_Type_II	297	14.2
Overweight_Level_II	290	13.9
Normal_Weight	282	13.5
Overweight_Level_I	276	13.2
Insufficient_Weight	267	12.8

현재 시각: 2026-08-27 13:15:54

데이터훑기 탭 - CSV를 올리면 행 2087개·열 17개와 결과 열(NObeyesdad) 값별 건수·비율이 바로 뜹니다.

비만 위험군 선별 프로젝트

문진(설문) 응답만으로, 비만이 될 위험이 큰 사람을 검사 전에 미리 가려내는 프로젝트

데이터 보기 전처리 학습 결과 리포트

빈칸 : 전체 0개

빈칸이 없습니다. 채울 것이 없어요

글자로 된 열 :

```
▼ [
  0 : "Gender"
  1 : "CALC"
  2 : "FAVC"
  3 : "SCC"
  4 : "SMOKE"
  5 : "family_history_with_overweight"
  6 : "CAEC"
  7 : "MTRANS"
]
```

글자 열을 어떻게 할까요

학습에서 빼기

결과 열에서 어느 값들을 1로 볼까요 (여러 개 고를 수 있어요)

Obesity_Type_I × Obesity_Type_II × Obesity_Type_III ×

학습용 비율(%)

80

학습용 80% / 시험용 20%

적용

빈칸 : 0개 → 0개

글자 열 ['Gender', 'CALC', 'FAVC', 'SCC', 'SMOKE', 'family_history_with_overweight', 'CAEC', 'MTRANS'] 을(를)
학습에서 뺐습니다

학습용 1669행 / 시험용 418행

	1 개수	1 비율(%)
학습용	777	46.6
시험용	195	46.7

현재 시각: 2026-08-27 13:16:00

전처리 탭 - Obesity_Type_I·II·III 을 1로 고르고 적용하면 학습용 1669행·시험용 418행으로 나뉘고, 비만 비율이 양쪽에 46.6%/46.7%로 비슷하게 맞춰집니다.

비만 위험군 선별 프로젝트

문진(설문) 응답만으로, 비만이 될 위험이 큰 사람을 검사 전에 미리 가려내는 프로젝트

데이터 보기 전처리 학습 **결과** 리포트

문턱(임계값)



지금 문턱 : 0.5

기준 모델과 내 모델 비교

	정확도	정밀도	재현율	F1
기준 모델(전부 정상)	0.533	0	0	0
로지스틱 회귀	0.943	0.943	0.933	0.938

지목한 건수 : 193건 (그중 진짜 불량 : 182건) / 놓친 건수 : 13건

혼동행렬 (시험용 기준)

	칸	건수	뜻
0	잡은 것	182	불량인데 불량이라고 맞힌 것
1	놓친 것	13	불량인데 정상이라고 놓친 것
2	헛경보	11	정상인데 불량이라고 잘못 잡은 것
3	정상을 정상이라 한 것	212	정상인데 정상이라고 맞힌 것

문턱별 비교 (0.1 ~ 0.9)

	문턱	지목 건수	그중 진짜	놓친 건수	정밀도	재현율	F1	표시
0	0.1	251	195	0	0.777	1	0.874	
1	0.2	233	195	0	0.837	1	0.911	
2	0.3	211	194	1	0.919	0.995	0.956	★ 최고 F1
3	0.4	203	187	8	0.921	0.959	0.94	
4	0.5	193	182	13	0.943	0.933	0.938	
5	0.6	181	174	21	0.961	0.892	0.926	
6	0.7	170	166	29	0.976	0.851	0.91	
7	0.8	164	161	34	0.982	0.826	0.897	
8	0.9	145	145	50	1	0.744	0.853	

F1이 가장 높은 문턱 : 0.3



결과 탭 - 문턱 0.5에서 기준 모델(정확도 0.533)과 로지스틱 회귀(정확도 0.943)를 표·혼동행렬·문턱 별 비교·중요 변수 그림까지 한 화면에서 볼 수 있습니다.

비만 위험군 선별 프로젝트

문진(설문) 응답만으로, 비만이 될 위험이 큰 사람을 검사 전에 미리 가려내는 프로젝트

데이터 훑기 전처리 학습 **결과** 리포트

문턱(임계값)



지금 문턱 : 0.5

기준 모델과 내 모델 비교

	정확도	정밀도	재현율	F1
기준 모델(전부 정상)	0.533	0	0	0
로지스틱 회귀	0.943	0.943	0.933	0.938

지목한 건수 : 193건 (그중 진짜 불량 : 182건) / 놓친 건수 : 13건


혼동행렬 (시험용 기준)

	칸	건수	뜻
0	잡은 것	182	불량인데 불량이라고 맞힌 것
1	놓친 것	13	불량인데 정상이라고 놓친 것
2	헛경보	11	정상인데 불량이라고 잘못 잡은 것
3	정상을 정상이라 한 것	212	정상인데 정상이라고 맞힌 것

문턱별 비교 (0.1 ~ 0.9)

	문턱	지목 건수	그중 진짜	놓친 건수	정밀도	재현율	F1	표시
0	0.1	251	195	0	0.777	1	0.874	
1	0.2	233	195	0	0.837	1	0.911	
2	0.3	211	194	1	0.919	0.995	0.956	★ 최고 F1
3	0.4	203	187	8	0.921	0.959	0.94	
4	0.5	193	182	13	0.943	0.933	0.938	
5	0.6	181	174	21	0.961	0.892	0.926	
6	0.7	170	166	29	0.976	0.851	0.91	
7	0.8	164	161	34	0.982	0.826	0.897	
8	0.9	145	145	50	1	0.744	0.853	

F1이 가장 높은 문턱 : 0.3



문턱 0.5(기본값) - 지목 193건 중 진짜 182건, 놓친 건수 13건, 헛경보 11건입니다.

비만 위험군 선별 프로젝트

문진(설문) 응답만으로, 비만이 될 위험이 큰 사람을 검사 전에 미리 가려내는 프로젝트

데이터 훑기 전처리 학습 **결과** 리포트

문턱(임계값)



지금 문턱 : 0.3

기준 모델과 내 모델 비교

	정확도	정밀도	재현율	F1
기준 모델(전부 정상)	0.533	0	0	0
로지스틱 회귀	0.957	0.919	0.995	0.956

지목한 건수 : 211건 (그중 진짜 불량 : 194건) / 놓친 건수 : 1건

혼동행렬 (시험용 기준)

	칸	건수	뜻
0	잡은 것	194	불량인데 불량이라고 맞힌 것
1	놓친 것	1	불량인데 정상이라고 놓친 것
2	헛경보	17	정상인데 불량이라고 잘못 잡은 것
3	정상을 정상이라 한 것	206	정상인데 정상이라고 맞힌 것

문턱별 비교 (0.1 ~ 0.9)

	문턱	지목 건수	그중 진짜	놓친 건수	정밀도	재현율	F1	표시
0	0.1	251	195	0	0.777	1	0.874	
1	0.2	233	195	0	0.837	1	0.911	
2	0.3	211	194	1	0.919	0.995	0.956	★ 최고 F1
3	0.4	203	187	8	0.921	0.959	0.94	
4	0.5	193	182	13	0.943	0.933	0.938	
5	0.6	181	174	21	0.961	0.892	0.926	
6	0.7	170	166	29	0.976	0.851	0.91	
7	0.8	164	161	34	0.982	0.826	0.897	
8	0.9	145	145	50	1	0.744	0.853	

F1이 가장 높은 문턱 : 0.3



문턱을 0.3으로 낮춘 뒤 - 지목이 211건으로 늘면서 진짜가 194건으로 늘고 놓친 건수는 1건으로 줄었지만, 헛경보는 11건에서 17건으로 늘었습니다.

7. 그래서 무엇을 하자는 것인가

모델이 비만 가능성이 높다고 지목한 사람은, 정밀 검사(체성분 검사 등)로 넘기기 전에 영양 상담 대상으로 먼저 불러들이자는 것입니다. 다만 지금 v1(기본 모델)로는 실제 비만 195건 중 111건만 걸러지므로, 이 상태로 현장에 바로 가는 것은 이릅니다.

8. 한계

- Age , FCVC , NCP , CH2O , FAF , TUE 에 정수가 아닌 값이 섞여 있습니다. 원 데이터 문서에 따르면 응답의 상당수가 SMOTE 같은 방법으로 합성됐다고 하며, 이 흔적으로 보입니다 — 즉 실제 사람의 응답 그대로가 아닐 수 있습니다
- 설문을 한 시점에 한 번에 걷은 데이터라, 계절이나 나이가 들면서 습관이 바뀌는 긴 흐름은 담겨 있지 않습니다
- 표본은 콜롬비아·페루·멕시코 응답자를 대상으로 한 설문이라, 다른 나라·다른 시기 사람에게 그대로 적용하기는 어렵습니다
- 특정 습관(예: 고칼로리 음식 섭취)에서 비만 단계가 높게 관찰되더라도, 습관과 비만 단계가 같은 시점에 함께 걷힌 것이라 그것이 원인이라고는 말할 수 없습니다

9. 다음에 할 일

1. 재검사(상담) 한 건에 드는 비용을 알아보고, 기본 모델과 가중치 모델 중 어느 쪽이 나은지 정하기
 2. 결과를 그림(그래프)으로 정리하기
-

저장소에 올린 날 : 2026-08-24